

EXTRAÇÃO E SELEÇÃO DE ATRIBUTOS

Maldição da dimensionalidade

2

- Maldição da dimensionalidade (ou *Curse of dimensionality*)
 - ▣ Termo que se refere a vários fenômenos que surgem na análise de dados em espaços com muitas dimensões (atributos)
 - Muitas vezes com centenas ou milhares de dimensões
 - ▣ Basicamente, adicionar características não significa sempre melhora no desempenho de um classificador

Maldição da dimensionalidade


3

- Suponha o seguinte problema
 - ▣ Um conjunto de dados é descrito por 20 atributos
 - Apenas 2 atributos são relevantes
 - Os demais são atributos ruins ou correlacionados
 - ▣ O resultado será um mau desempenho na classificação
 - O algoritmo K-NN é normalmente enganado quando o número de atributos é grande
 - Assim como outros classificadores também tem seu desempenho prejudicado

Maldição da dimensionalidade

4

- De modo geral, o desempenho de um classificador tende a se degradar a partir de um determinado nº de atributos
 - ▣ Mesmo que eles sejam atributos úteis



Maldição da dimensionalidade



5

- 1 atributo = 1 dimensão no espaço de características
 - ▣ Hiper-volume cresce exponencialmente com a adição de novos atributos
 - 1 atributo com 10 possíveis valores: 10 possíveis objetos
 - 5 atributos com 10 possíveis valores: 10^5 possíveis objetos
 - ▣ Em espaços com muitas dimensões as amostras se tornam esparsas e pouco similares
 - Objetos muito distantes uns dos outros
 - Objetos parecem equidistantes

Maldição da dimensionalidade

6

- Mais dimensões = dados mais esparsos
 - ▣ Redução de dimensionalidade pode trazer vários benefícios



Redução da dimensionalidade

7

- Trata-se de uma etapa importante no projeto de um sistema de classificação
 - ▣ Consiste em utilizar um número pequeno de atributos no classificador
 - ▣ Para tanto, faz-se a seleção e/ou composição de atributos mais adequados a partir dos originalmente disponíveis

Redução da dimensionalidade

8

- Vantagens
 - ▣ Melhora a eficácia dos classificadores
 - Elimina atributos irrelevantes ou redundantes
 - ▣ Reduz o tamanho necessário da amostra
 - ▣ Melhora a eficiência computacional dos algoritmos
 - Menos atributos envolvidos
 - ▣ Simplifica modelo gerado e facilita interpretação
 - ▣ Facilita visualização dos dados

Redução da dimensionalidade

9

- Essencialmente, podemos reduzir a dimensionalidade de duas maneiras
 - ▣ Criação de “novos” atributos via transformação dos dados
 - Agregação de atributos
 - Extração de características
 - ▣ Seleção de atributos
 - Busca de um conjunto sub ótimo de atributos

Agregação de atributos


10

- Uma forma elementar de reduzir complexidade dos dados é agregar atributos
- Exemplo: dois atributos, “massa” e “volume”
 - ▣ Esses atributos podem ser agregados em um único atributo: “densidade”
 - $\text{densidade} = \text{massa} / \text{volume}$
 - ▣ Nesse caso, não há perda de informação relevante a um dado problema de interesse em particular

Seleção de atributos

11

- *Feature selection* em inglês
 - ▣ Assume que os atributos existentes já estão em uma forma apropriada. No entanto
 - Alguns podem ser irrelevantes
 - Outros podem ser redundantes
 - ▣ Tais atributos podem ser descartados



Seleção de atributos

12

- Normalmente utiliza uma estratégia de busca que decide a maneira como as combinações de atributos são testadas de acordo com um certo critério de qualidade
 - ▣ Busca por **ordenação**
 - ▣ Seleção de **subconjunto**

Seleção de atributos

13

- Busca por **ordenação**
 - ▣ Ordena os atributos de acordo com sua relevância
 - ▣ Seleciona os mais relevantes segundo alguma medida
 - discriminação (para classificação)
 - prever uma saída (regressão)
 - ▣ Relevância depende da natureza do problema e dos atributos envolvidos
- Seleção de **subconjunto**
 - ▣ Seleciona um subconjunto de atributos mutuamente relevantes

Seleção de atributos

14

- Exemplo: busca por ordenação
 - ▣ Ordenar os atributos mais importantes para o diagnóstico de pacientes

Febre	Enjoo	Mancha	Dor	Diagnóstico
1	1	0	1	0
0	1	0	0	1
1	1	1	0	1
1	0	0	1	0
1	0	1	1	1
0	0	1	1	0

Seleção de atributos

15

- Exemplo: busca por ordenação
 - ▣ Atributos binários: relevância de cada atributo é estimada de acordo com o diagnóstico (exemplo apenas pedagógico)

Febre	Enjoo	Mancha	Dor
3/6	4/6	4/6	1/6

Febre	Enjoo	Mancha	Dor	Diagnóstico
1	1	0	1	0
0	1	0	0	1
1	1	1	0	1
1	0	0	1	0
1	0	1	1	1
0	0	1	1	0

Seleção de atributos

16

- Exemplo: busca por ordenação
 - ▣ Atributos ordenados: 2 atributos (**enjoo** e **mancha**) classificam corretamente 4/6 dos casos

Enjoo	Mancha	Febre	Dor
4/6	4/6	3/6	1/6

Febre	Enjoo	Mancha	Dor	Diagnóstico
1	1	0	1	0
0	1	0	0	1
1	1	1	0	1
1	0	0	1	0
1	0	1	1	1
0	0	1	1	0

Seleção de atributos

17

- Vantagem da busca por ordenação
 - ▣ A seleção dos atributos tem complexidade linear
 - Seleção, não a ordenação
 - ▣ Muito mais simples que combinar os atributos
 - Dado ***N*** atributos, o número de possíveis combinações de ***n*** atributos dentre ***N*** é

$$\binom{N}{n} = \frac{N!}{(N-n)!n!}$$
 - Para ***N* = 40** e ***n* = 5**, temos **658.008** combinações

Seleção de atributos

18

- Desvantagem da busca por ordenação
 - ▣ Ordenação é deficiente: despreza correlação e redundância entre atributos
 - Atributos inúteis sozinhos porém úteis em conjunto
 - Atributos são tão úteis sozinhos quanto em conjunto
 - ▣ Nem sempre os melhores ***n*** atributos constituem o melhor subconjunto
 - Atributos devem ser não correlacionados
 - O melhor subconjunto é o mais complementar

Seleção de atributos

19

- Avaliar todos os subconjuntos de atributos é inviável
 - ▣ Por que não utilizar um critério de avaliação nessa busca?
- Busca heurística
 - ▣ Alguns subconjuntos são avaliados segundo algum critério até que um critério de parada seja satisfeito
 - ▣ Utiliza uma estratégia de busca para escolher os subconjuntos avaliados

Seleção de atributos

20

- Estratégias de Busca
 - ▣ Backward Elimination
 - Inicia com todos os atributos e remove um atributo por vez do conjunto
 - ▣ Forward Selection
 - Inicia com nenhum atributo e inclui um atributo por vez no conjunto
 - ▣ Bidirectional Search
 - A busca pode começar em qualquer ponto e atributos podem ser adicionados e removidos
 - ▣ Random Search
 - Ponto de partida da busca e atributos a serem removidos ou adicionados são decididos de forma estocástica

Seleção de atributos

21

- Critérios de Avaliação
 - ▣ Inerente ao método de seleção de atributos
 - ▣ Critérios independentes
 - Medidas de correlação
 - Medidas de informação
 - Medidas de dependência
 - Medidas de consistência
 - ▣ Critérios dependentes
 - Algoritmo alvo usado para a tarefa de interesse

Seleção de atributos

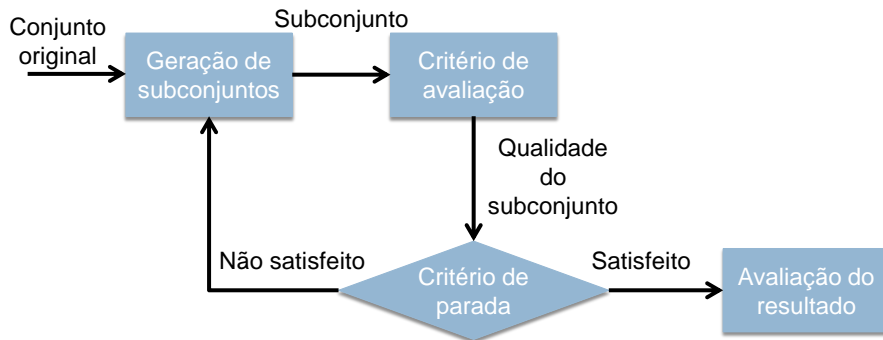
22

- Critério de Parada
 - ▣ De modo geral, depende do método de busca utilizado
 - ▣ Algumas possibilidades
 - Número máximo de iterações
 - Valor do critério de avaliação obtido
 - Etc.

Seleção de atributos

23

- Visão geral do processo de seleção de subconjunto



Seleção de atributos

24

- Existem diferentes maneiras de se fazer a seleção de atributos. Elas podem ser agrupadas em 3 categorias independentes
 - ▣ Filtros
 - Seleção de atributos é realizada a priori
 - ▣ Wrappers
 - O algoritmo de aprendizado é usado para guiar o processo de seleção
 - ▣ Embarcados (Embedded)
 - Processo de seleção faz parte do algoritmo de aprendizado


Seleção de atributos

25

□ Filtros

▣ Seleção de atributos é realizada a priori

- Basicamente, fazem uso de alguma heurística para executar uma busca nos atributos
- Considera apenas as propriedades intrínsecas aos próprios dados
- Processamento mais rápido



Seleção de atributos

26

□ Filtros

▣ Critérios de busca

- Medidas de correlação / informação mútua entre atributos
- Medidas de relevância e redundância
- Privilegiam conjuntos de atributos muito relacionados com a saída desejada e pouco relacionados entre si

▣ Desvantagem

- Seleção de forma indireta, o que pode levar a resultados inferiores

Seleção de atributos

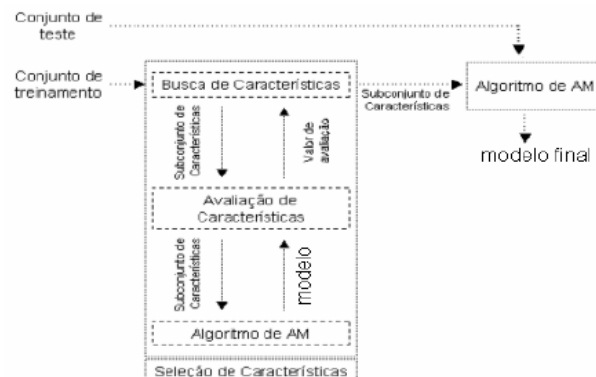
27

- Wrappers
 - ▣ O algoritmo de aprendizado utilizado é usado para guiar o processo de seleção
 - Utilizam alguma heurística para executar uma busca
 - Uso do algoritmo de aprendizado: maximização do seu desempenho
 - ▣ Implica, em geral, em tornar o método muito custoso em termos computacionais
 - Custo pode se tornar proibitivo

Seleção de atributos

28

- Wrappers



Seleção de atributos

29

- Embarcados (Embedded)
 - ▣ Processo de seleção faz parte do algoritmo de aprendizado
 - Parte interna e natural do algoritmo de aprendizado
 - ▣ Exemplo
 - Classificadores baseados em Árvores de Decisão

Extração de características


30

- *Feature extraction* em inglês
 - ▣ Consiste em extrair, a partir dos dados brutos, características de alto nível com grande riqueza de informação relevante sobre os dados
 - ▣ Exemplo:
 - Informações sobre bordas, contornos, sombras e formas geométricas em fotografias (pixels não são bons atributos)
 - Componentes harmônicas de frequência em sinais de áudio

Extração de características

31

- Exemplo de extração de características



Extração de características

32

- Um exemplo é a *Transformação do Espaço de Atributos*
 - ▣ Gera um novo conjunto de atributos a partir da combinação de projeções dos atributos originais
 - ▣ Ex.: PCA (linear) ou Kernel PCA (não linear)
- Atributos são ortogonais (perpendiculares) e ordenados segundo a parcela de informação que conduzem
 - ▣ Podemos descartar os atributos menos representativos
 - ▣ Resultado é um espaço de dimensão menor que o original contendo a maior parcela possível da informação

Extração de características

33

- Vantagens
 - ▣ Simples e computacionalmente rápida em especial PCA linear
- Desvantagens
 - ▣ Técnica limitada a atributos numéricos
 - ▣ Novos atributos não podem ser interpretados como os originais
 - Atributos físicos deixam de ter um significado físico
 - Muito ruim para determinadas aplicações

Análise de Componentes Principais - PCA

34

- *Principal Component Analysis* em inglês
 - ▣ Forma de identificar padrões nos dados
 - Colocando em evidência suas relações, similaridades e diferenças
 - ▣ Especialmente importante para altas dimensões
 - Análise visual não é possível
 - ▣ Extrator de características
 - Uma vez encontrados os padrões, podemos comprimir os dados sem grande perda de qualidade

Análise de Componentes Principais - PCA

35

□ Histórico

▣ Pearson (1901)

- Criou a Componente Principal (PC)
- Procurava linhas e planos que melhor se adequavam a um conjunto de pontos em um espaço p -dimensional

▣ Hotelling (1933)

- Procurava encontrar um pequeno conjunto de variáveis fundamentais que expressa p variáveis
- Hotelling procurou maximizar suas “componentes” no senso da variância das variáveis originais. Chamou de Componentes Principais

Análise de Componentes Principais - PCA

36

□ Histórico

▣ Pearson e Hotelling esbarraram no cálculo dos autovetores

- Difícil de calcular para ordem > 4
- PCA é mais eficiente para conjuntos de dados de alta dimensão. Sem aplicação na época

▣ Retomada nos anos 60

- Primeiros computadores capazes de resolver o problema dos autovetores de maneira rápida

Análise de Componentes Principais - PCA

37

- Idéia básica
 - ▣ Um número p de atributos dependentes podem ser expressas como um número t de atributos independentes
 - Sendo $t \ll p$
 - ▣ Considere um conjunto de vetores \mathbf{x}
 - Pode-se sempre gerar uma combinação linear que mapeia o vetor \mathbf{x} no vetor \mathbf{y}
 - Espaço definido por variáveis ortonormais (norma igual a 1)

Análise de Componentes Principais - PCA

38

- Combinação linear de \mathbf{x} em \mathbf{y}
 - ▣ Transformação sem perda de informação

$$x = \sum_{j=1}^{\infty} y_j e_j$$

- ▣ Considerando apenas t dimensões
 - Nesse caso, teremos alguma perda de informação

$$\hat{x} = \sum_{j=1}^t y_j e_j$$

Análise de Componentes Principais - PCA

39

- Definição matemática
 - ▣ Transformação linear ortogonal dos dados
 - ▣ Dados agrupados da seguinte forma
 - A maior variância por qualquer projeção dos dados fica ao longo da primeira coordenada (**primeiro componente**)
 - A segunda maior variância fica ao longo da segunda coordenada (**segundo componente**)
 - E assim por diante

Análise de Componentes Principais - PCA

40

- Etapas para o cálculo do PCA
 - ▣ Transformação dos dados envolve conceitos matemáticos relativamente simples
 - Subtrair a média dos dados (para cada atributo)
 - Calcular a matriz de covariâncias
 - Cálculo dos autovetores e autovalores da matriz de covariâncias
 - Ordenação dos autovetores por ordem de importância
 - Mapear os dados para o novo espaço

Análise de Componentes Principais - PCA

41

- Autovetores e autovalores
 - ▣ Um vetor \mathbf{v} é um **autovetor** de uma matriz quadrada \mathbf{M} se
 - $\mathbf{M}\mathbf{v}$ (multiplicação da matriz \mathbf{M} pelo vetor \mathbf{v}) resulta num múltiplo de \mathbf{v} , ou seja, em $\lambda\mathbf{v}$ (multiplicação de um escalar pelo vetor)
 - Nesse caso, λ é o chamado autovalor de \mathbf{M} associado ao vetor \mathbf{v}

Análise de Componentes Principais - PCA

42

- Autovetores e autovalores

a matriz

$$A = \begin{bmatrix} 8 & 1 & 2 \\ -1 & 5 & 1 \\ 0 & 1 & 90 \end{bmatrix},$$

tem como autovalores e respectivos autovetores,

$$\lambda_1 = 90,0115, \quad \lambda_2 = 7,6308, \quad \lambda_3 = 5,3577$$


$$x_1 = \begin{bmatrix} 0,0245 \\ 0,0115 \\ 0,9996 \end{bmatrix}, \quad x_2 = \begin{bmatrix} -0,9353 \\ 0,3539 \\ -0,0043 \end{bmatrix}, \quad x_3 = \begin{bmatrix} -0,0043 \\ -0,0111 \\ 0,9996 \end{bmatrix}$$

Análise de Componentes Principais - PCA

43

- Vamos calcular o PCA para o seguinte conjunto de dados

x	y
2,5	2,4
0,5	0,7
2,2	2,9
1,9	2,2
3,1	3
2,3	2,7
2	1,6
1	1,1
1,5	1,6
1,1	0,9




Análise de Componentes Principais - PCA

44

- O primeiro passo é subtrair a média dos dados
 - ▣ Não fazer o zscore (precisamos da variância!)

x	y
0,69	0,49
-1,31	-1,21
0,39	0,99
0,09	0,29
1,29	1,09
0,49	0,79
0,19	-0,31
-0,81	-0,81
-0,31	-0,31
-0,71	-1,01




Análise de Componentes Principais - PCA

45

- Na sequência, obtemos a matriz de covariância dos dados

x	y		
0,69	0,49		
-1,31	-1,21		
0,39	0,99		
0,09	0,29		
1,29	1,09		
0,49	0,79		
0,19	-0,31		
-0,81	-0,81		
-0,31	-0,31		
-0,71	-1,01		



0,6166	0,6154
0,6154	0,7166

Análise de Componentes Principais - PCA

46

- A partir da matriz de covariância, obtemos os seus autovetores e autovalores


			autovalores
0,6166	0,6154	0,0490	1,2840
0,6154	0,7166	-0,7351	-0,6778
		0,6778	-0,7351
			autovetores

Análise de Componentes Principais - PCA

47

- Autovetores nos fornecem informações sobre os padrões nos dados
 - ▣ Um deles passa pelo meio dos pontos (quase uma regressão)

autovalores	
0,0490	1,2840
-0,7351	-0,6778
0,6778	-0,7351
autovetores	



Análise de Componentes Principais - PCA

48

- Temos que o autovetor com o maior autovalor é o componente principal do conjunto dos dados
 - ▣ Ordenar do maior para o menor

autovalores	
0,0490	1,2840

autovalores	
1,2840	0,0490

-0,7351	-0,6778
0,6778	-0,7351



-0,6778	-0,7351
-0,7351	0,6778

autovetores

autovetores

Análise de Componentes Principais - PCA

49

- Uma vez ordenados, podemos escolher os componentes que nos interessam
 - ▣ Podemos escolher todos
 - ▣ Podemos descartar os menos significantes
 - Reduzindo assim a dimensionalidade dos dados

autovalores

1,2840	0,0490
--------	--------

autovalores

1,2840

OU

-0,6778	-0,7351
---------	---------

-0,7351	0,6778
---------	--------

autovetores

-0,6778

-0,7351

autovetores

Análise de Componentes Principais - PCA

50

- Para obter os dados transformados pelo PCA
 - ▣ Multiplicar os dados (com a média subtraída deles) pelos autovetores escolhidos
 - Dados transformados expressam os padrões entre eles
 - Os *Componentes Principais* são combinações lineares de todos os atributos, produzindo assim novos atributos não correlacionados

Análise de Componentes Principais - PCA

51

- Obtendo os dados transformados

x	y	X	<div><div><div>-0,6778</div><div>-0,7351</div></div><div><div>-0,7351</div><div>0,6778</div></div></div>	=	X	y
0,69	0,49				0,82	-0,17
-1,31	-1,21				-1,77	0,14
0,39	0,99				0,99	0,38
0,09	0,29				0,27	0,13
1,29	1,09				1,67	-0,20
0,49	0,79				0,91	0,17
0,19	-0,31				-0,09	-0,34
-0,81	-0,81				-1,14	0,04
-0,31	-0,31				-0,43	0,01
-0,71	-1,01				-1,22	-0,16


Análise de Componentes Principais - PCA

52

- Obtendo os dados transformados

Dados sem
média

x	y
0,69	0,49
-1,31	-1,21
0,39	0,99
0,09	0,29
1,29	1,09
0,49	0,79
0,19	-0,31
-0,81	-0,81
-0,31	-0,31
-0,71	-1,01

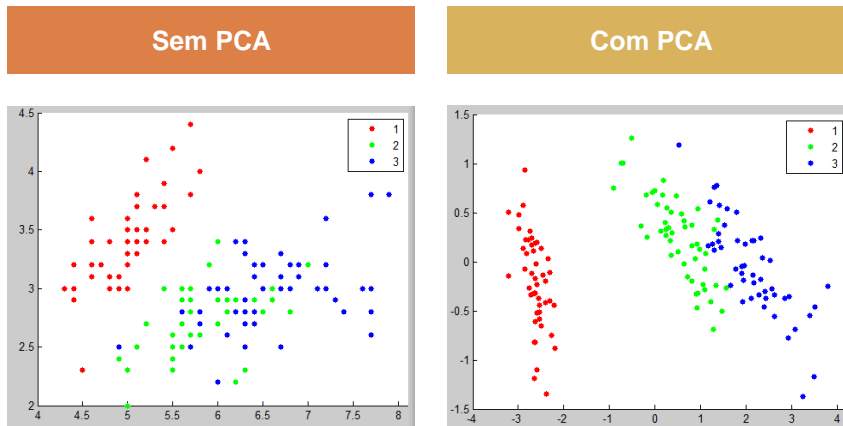


PCA

X	y
0,82	-0,17
-1,77	0,14
0,99	0,38
0,27	0,13
1,67	-0,20
0,91	0,17
-0,09	-0,34
-1,14	0,04
-0,43	0,01
-1,22	-0,16

PCA - Iris

53



PCA - Iris

54

- Classificação com Knn ($k = 1$)
 - ▣ Sem PCA
 - 4 atributos: 94,67%
 - ▣ Com PCA
 - 1 componente: 88,67%
 - 2 componentes: **94,00%**
 - 3 componentes: 90,67%
 - 4 componentes: 90,67%
 - ▣ Redução do conjunto de atributos pela **metade** com perda de apenas **0,67%**

Análise de Componentes Principais - PCA


55

- Problemas
 - ▣ Voltado apenas para atributos numéricos
 - Não há sentido em trabalhar com atributos discretos, mesmo depois de uma etapa de conversão
 - ▣ Caso os p atributos não tenham as mesmas unidades de medida, a combinação linear é insensata do ponto de vista “físico”
 - ▣ Só é possível extrair uma projeção linear dos dados

Análise de Componentes Principais - PCA

56

- PCA = projeção linear dos dados
 - ▣ Para certos conjuntos de dados isso não funciona muito bem



Kernel PCA

57

- Solução
 - ▣ Encontrar uma transformação não linear, isto é, um **Kernel**
 - Essa transformação mapeia o espaço original dos padrões para um novo espaço de atributos
 - Nesse novo espaço, os padrões x passam a ser linearmente separáveis

Kernel PCA

58

- Idéia básica
 - ▣ Utilizar uma função Kernel não linear de forma a calcular o PCA em um espaço de maior dimensão
 - ▣ Esse espaço é não linearmente relacionado ao espaço original

Kernel PCA


59

- Possível solução
 - ▣ Projetar os dados em um espaço de maior dimensão
 - ▣ Subtrair a média dos dados transformados (para cada atributo)
 - ▣ Calcular a matriz de covariâncias
 - ▣ Cálculo dos autovetores e autovalores da matriz de covariâncias
 - ▣ Ordenação dos autovetores por ordem de importância
 - ▣ Mapear os dados para o novo espaço

Kernel PCA

60

- Felizmente, Kernel PCA pode ser calculado de forma implícita
 - ▣ Sem necessidade de transformação dos dados



Análise de Componentes Independentes - ICA

61

- *Independent Component Analysis* em inglês
 - ▣ É uma extensão da abordagem do PCA
 - Trata-se de um método computacional para a separação de um conjunto de dados em subcomponentes aditivos
 - Supõe a independência estatística ao invés da decorrelação dos dados

Análise de Componentes Independentes - ICA

62

- *Decorrelação versus independência*
 - ▣ PCA – decorrelação dos dados
 - Se dois atributos são decorrelacionados sua covariância é zero
 - Trabalha com média nula, o que leva a condição de ortogonalidade (perpendicularidade) da construção das direções de projeção dos componentes principais
 - Com isso, tem-se componentes de máxima variância
 - Decorrelação **linear** não implica na ocorrência de decorrelação **não linear**

Análise de Componentes Independentes - ICA


63

- *Descorrelação versus independência*
 - ▣ ICA – independência dos dados
 - Independência estatística acarreta toda e qualquer decorrelação **não linear**
 - Componentes independentes: componentes **linear** e **não linearmente** decorrelacionados
 - Preço disso tudo: para quantificar essa independência

Análise de Componentes Independentes - ICA

64


- *Motivação: separação cega de fontes*
 - ▣ Problema “cocktail party”
 - Separação de sinais de áudio
 - Duas pessoas conversando em uma sala fechada utilizando sensores (microfones) para capturar suas vozes
 - Como separar os sinais captados pelos microfones sabendo que os sinais estão agora correlacionados?




Análise de Componentes Independentes - ICA

65

Discursos originais



Discursos misturados



Análise de Componentes Independentes - ICA

66

- Modelo de mistura
 - ▣ Os dados observados \mathbf{x} consistem de uma combinação linear de n atributos estatisticamente independentes, \mathbf{s}

$$x(i) = a_1(i)s_1(i) + a_2(i)s_2(i) + \dots + a_n(i)s_n(i)$$

- ▣ Em forma matricial

$$\mathbf{x} = \mathbf{A}\mathbf{s}$$

- ▣ Onde \mathbf{A} são os coeficientes de misturas

Análise de Componentes Independentes - ICA

67

- Modelo de mistura
 - ▣ Os componentes independentes podem ser obtidos pela inversa de **A**, **W**

$$s = Wx$$

- ▣ Problema
 - A matriz **A** é, em geral, desconhecida
 - Porém, podemos fazer uma boa estimativa dela

Análise de Componentes Independentes - ICA

68


- Etapas para o cálculo do ICA
 - ▣ Transformação dos dados envolve conceitos matemáticos relativamente simples
 - Subtrair a média dos dados (para cada atributo)
 - Branqueamento ou *whitening*
 - Cálculo da matriz de mistura ortogonal
 - Mapear os dados para o novo espaço

Análise de Componentes Independentes - ICA

69

- Vamos calcular o ICA para o seguinte conjunto de dados

x	y
2,5	2,4
0,5	0,7
2,2	2,9
1,9	2,2
3,1	3
2,3	2,7
2	1,6
1	1,1
1,5	1,6
1,1	0,9




Análise de Componentes Independentes - ICA

70

- O primeiro passo é subtrair a média dos dados
 - ▣ Não fazer o zscore (precisamos da variância!)

x	y
0,69	0,49
-1,31	-1,21
0,39	0,99
0,09	0,29
1,29	1,09
0,49	0,79
0,19	-0,31
-0,81	-0,81
-0,31	-0,31
-0,71	-1,01



Análise de Componentes Independentes - ICA

71

- Branqueamento ou *whitening*
 - ▣ Dado uma amostra \mathbf{x} centralizada (média zero), esse processo torna os atributos descorrelacionados e com variância igual a 1
 - Sua matriz de correlação fica igual a matriz identidade

Análise de Componentes Independentes - ICA

72

- Branqueamento ou *whitening*
 - ▣ Esse processo é obtido com a seguinte transformação linear
 - $\mathbf{z} = \mathbf{x}\mathbf{V}$
 - ▣ Onde $\mathbf{V} = \mathbf{E}\mathbf{D}^{-\frac{1}{2}}\mathbf{E}^t$
 - \mathbf{E} é a matriz ortogonal dos autovetores da matriz de covariância
 - \mathbf{D} é a matriz diagonal dos autovalores da matriz de covariância

Análise de Componentes Independentes - ICA

73

- Branqueamento ou *whitening*
 - ▣ Obtendo os dados transformados

x	y		X	y
0,69	0,49		1,0764	0,0013
-1,31	-1,21		-1,5374	-0,7161
0,39	0,99		-0,6819	1,8198
0,09	0,29		-0,2687	0,5769
1,29	1,09	X	2,8451	-1,8096
0,49	0,79		-1,8096	2,5511
0,19	-0,31	=	1,6976	0,4462
-0,81	-0,81		-0,0355	1,1286
-0,31	-0,31		1,1015	-1,1346
-0,71	-1,01		-0,8387	-0,6005
			-0,3210	-0,2298
			-0,1923	-1,2917

Análise de Componentes Independentes - ICA

74

- Matriz de mistura ortogonal
 - ▣ A partir dos dados “branqueados” podemos obter a matriz de misturas que dá origem aos componentes independentes \mathbf{s}

$$\mathbf{s} = \mathbf{W}\mathbf{x}$$
 - ▣ Existem várias abordagens para se obter essa matriz
 - Maximização da Não Gaussianidade (kurtosis)
 - Usando PCA: *P-ICA*
 - Estimativa da Máxima Probabilidade
 - Minimização da Informação Mútua
 - Métodos Tensoriais
 - Entre outros

Análise de Componentes Independentes - ICA

75

- Usando PCA: *P-ICA*
 - ▣ PCA e ICA
 - Transformação linear dos dados
 - Exploram os dados de formas diferentes
 - ▣ PCA
 - Utiliza a distribuição conjunta gaussiana para ajustar os dados
 - Busca uma transformação ortogonal que faz a distribuição conjunta gaussiana fatorável independente da verdadeira distribuição dos dados

Análise de Componentes Independentes - ICA

76

- Usando PCA: *P-ICA*
 - ▣ ICA
 - Busca uma transformação linear que faz a verdadeira distribuição conjunta dos dados transformados fatorável, de modo que as saídas são mutuamente independentes.

Análise de Componentes Independentes - ICA


77

- Usando PCA: *P-ICA*
 - ▣ Como fazer?
 - Branqueamento do conjunto \mathbf{x} de dados: \mathbf{v}
 - Transformação $\mathbf{z} = \mathbf{v}/\|\mathbf{v}\|$
 - Obter a matriz ortogonal \mathbf{U} usando PCA em \mathbf{z}
 - A matriz de separação é dada por $\mathbf{W} = \mathbf{U}\mathbf{V}$

Análise de Componentes Independentes - ICA

78


- Exemplo
 - ▣ Dados originais



Análise de Componentes Independentes - ICA

79


- Exemplo
 - ▣ Dados misturados



Análise de Componentes Independentes - ICA

80

- Exemplo
 - ▣ Dados separados



- Agradeço ao professor
 - ▣ Prof. Ricardo J. G. B. Campello – ICMC/USP
- E ao doutorando
 - ▣ Nielsen Castelo Damasceno - UFRN
- pelo material disponibilizado